




# Introdução ao Aprendizado de Máquina

Prof. Bruno Nogueira

*“ Na medida que os computadores se tornam mais sofisticados, parece inevitável que o Aprendizado de Máquina exercerá um papel central em Ciência da Computação e tecnologia de computadores” - Tom Mitchell*

# Inteligência x Aprendizado

- ▶ **Aprendizado** é a chave da superioridade da inteligência humana
- ▶ Aprendizado é a essência da inteligência
- ▶ Para que uma máquina tenha **Comportamento Inteligente**, deve-se aumentar sua **Capacidade de Aprendizado**



# Objetivos do estudo de AM

---

- ▶ Entender melhor os mecanismos de aprendizado humano pode levar a um melhor entendimento das capacidades (e incapacidades) humanas
- ▶ Automatizar processo de aquisição de conhecimento
  - ▶ Modelar computacionalmente processo de aprendizado humano
  - ▶ Abre novas oportunidades para uso de computadores

# Aprendizado de Máquina

---

## ▶ Quadro atual

- ▶ Capacidade de aprendizado dos computadores de maneira geral ainda é muito inferior àquela dos seres humanos
- ▶ Porém, algoritmos de AM eficientes têm sido propostos para várias tarefas
- ▶ Entendimento teórico de aprendizado começa a se consolidar

# Aprendizado de Máquina (AM)

---

- ▶ Sub-área da Inteligência Artificial que pesquisa **métodos computacionais** relacionados à aquisição de **novos conhecimentos, novas habilidades e novas formas de organizar** o conhecimento já existente
- ▶ Computadores são capazes de aprender?
  - ▶ **Sim.** Mas nem de perto tal como um humano aprende!
  - ▶ Computador não possui programa inicial para procurar por informações e realizar aprendizado em geral
  - ▶ Paradigmas e técnicas de Aprendizado de Máquina possuem um alvo bem mais limitado do que o aprendizado humano.

# Aprendizado de Máquina (AM)

---

- ▶ Algoritmos de AM têm sido bem sucedidos, p. ex., para:
  - ▶ Identificar genes associados a determinadas doenças
  - ▶ Discriminar tecidos (saudáveis e doentes), objetos celestiais, ...
  - ▶ Identificar nichos de mercado
  - ▶ Prever a vazão de rios e nível de represas
  - ▶ Detectar uso fraudulento de cartões de crédito
  - ▶ Otimizar ações de controle em processos de produção
  - ▶ Reconhecimento de faces, de voz, de assinaturas ...
  - ▶ e tantas outras...

# Aprendizado de Máquina (AM)

---

- ▶ Uma das áreas de aplicação mais importantes de AM tem sido a descoberta de conhecimento em grandes bases de dados (KDD)
  - ▶ Mineração de Dados (Data Mining – DM)
  - ▶ Exemplos:
    - ▶ Registros de compras em grandes supermercados
    - ▶ Registros de empréstimos financeiros
    - ▶ Registros de transações financeiras
    - ▶ Registros médicos
    - ▶ Projetos genoma
    - ▶ ...
  - ▶ Veremos Mineração de Dados mais adiante no semestre...



# Aprendizado de Máquina (AM)

---

## ▶ Por que AM é importante?

- ▶ Algumas tarefas não podem ser bem executadas sem que seja por meio de exemplos
  - ▶ Ex.: Reconhecer pessoas
- ▶ Ser humano não é capaz de explicar (e portanto de programar) sua habilidade para executar alguns tipos de tarefas
  - ▶ Ex.: Andar de bicicleta
- ▶ Quantidade de conhecimento disponível pode ser muito grande para ser descrito (e portanto programado) por humanos
  - ▶ Ex.: Diagnóstico médico

# Aprendizado de Máquina (AM)

---

- ▶ Por que AM é importante?
  - ▶ Ser humano não é capaz de executar algumas tarefas que demandam quantidades grandes de cálculos complexos, passíveis apenas de execução em computador:
    - ▶ P. ex., detectar inter-relacionamentos / correlações escondidas em grandes quantidades de dados
    - ▶ AM e MD podem encontrar essas relações
  - ▶ Ambientes (e perfis dos problemas) podem mudar com o tempo
    - ▶ Capacidade de adaptação automática é fundamental

# Aprendizado de Máquina (AM)

---

- ▶ Definição formal (Mitchell, 1997):
  - ▶ “Um programa de computador é dito **aprender** a partir de uma experiência **E** com respeito a uma classe de tarefas **T** e medida de desempenho **P**, se seu desempenho em tarefas de **T**, medido por **P**, melhora com a experiência **E**”.
- ▶ Em AM, trabalha-se com **problemas bem definidos**
  - ▶ Três características devem ser identificadas para um problema ser bem definido
    - ▶ A **classe de tarefas**
    - ▶ A **medida de desempenho** a ser melhorada
    - ▶ A **origem da experiência**


# Exemplos – Problemas bem definidos

---

- ▶ **Aprender a jogar xadrez**
  - ▶ Tarefa T: jogar xadrez
  - ▶ Medida de desempenho P: % de vitórias contra oponentes
  - ▶ Experiência de treino E: jogar xadrez contra si mesmo
- ▶ **Navegação de robôs**
  - ▶ T: dirigir em uma estrada pública usando sensores de visão
  - ▶ P:
  - ▶ E:
- ▶ **Filtro de SPAM's**
  - ▶ T:
  - ▶ P:
  - ▶ E:

# Interdisciplinaridade em AM

---



# Aprendizado por Indução

---

- ▶ **Inferência Indutiva** é um dos principais meios para a aquisição de novos conhecimentos e previsão de eventos futuros
- ▶ Observações permitem descobrir **regras** e **procedimentos**
- ▶ Deve-se ter cuidado com o número de observações e a relevância dos dados

# Argumentos Dedutivos vs. Indutivos

---

## ▶ Argumento **dedutivo**

- ▶ Nenhum dos alunos gosta de Inteligência Artificial
- ▶ Frederico é um aluno

➡ Frederico não gosta de Inteligência Artificial

## ▶ Argumento **indutivo**

- ▶ Nenhum dos alunos que foram entrevistados gosta de Inteligência Artificial

➡ Nenhum aluno gosta de Inteligência Artificial

# Argumentos Dedutivos vs. Indutivos

---

| Argumentos Dedutivos                                                                                         | Argumentos Indutivos                                                                                                                                                                                   |
|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>Se todas as premissas são verdadeiras, a conclusão é verdadeira.</p>                                      | <p>Se todas as premissas são verdadeiras, a conclusão é <b><u>provavelmente</u></b> verdadeira, mas não <b><u>necessariamente</u></b> verdadeira (à exceção dos argumentos matemáticos indutivos).</p> |
| <p>Toda a informação do conteúdo fatural da conclusão já está, pelo menos implicitamente, nas premissas.</p> | <p>A conclusão contém informação que não está nem implicitamente nas premissas.</p>                                                                                                                    |



# Modelo indutivo

---

- ▶ Por meio de **argumentos indutivos**, em Aprendizado de máquina geram-se **modelos indutivos** formados por hipóteses que representam o conhecimento aprendido
- ▶ Por meio de um conjunto de experiência **E** para uma tarefa **T**, ajusta-se um modelo indutivo representado por uma função **h** que busque maximizar uma medida de desempenho **P**
- ▶ Exemplo: jogar xadrez
  - ▶ Modelo indutivo  $h$  é ajustado de acordo com os jogos apresentados de maneira a sempre obter mais vitórias.
- ▶ Como o modelo indutivo é ajustado?
  - ▶ De acordo com algum dos paradigmas de aprendizado indutivo
  - ▶ Paradigmas de **treinamento**


# Aprendizado Indutivo

---

- ▶ Forma mais simples: aprender uma função a partir de exemplos.
  - ▶  $f$  é a **função alvo**;
  - ▶ Um **exemplo** é um par  $(x, f(x))$  ;
- ▶ Problema: encontrar a **hipótese**  $h$ 
  - ▶ Tal que  $h \approx f$
  - ▶ dado um conjunto de treinamento de exemplos.
- ▶ Este é um modelo super-simplificado do aprendizado real:
  - ▶ Ignora conhecimento prévio;
  - ▶ Assume que exemplos são fornecidos.


# Método de Aprendizado Indutivo

- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:




# Método de Aprendizado Indutivo

- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:




# Método de Aprendizado Indutivo

- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:



# Método de Aprendizado Indutivo


- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:



# Método de Aprendizado Indutivo


---

- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:



# Método de Aprendizado Indutivo

- ▶ Construir/ajustar  $h$  para a função  $f$  no conjunto de treinamento.
- ▶  $h$  é **consistente** se se ajusta a  $f$  em todos os exemplos.
- ▶ E.g., ajuste de curvas:



- ▶ Navalha de Ockham: preferir a hipótese mais simples que seja consistente com os dados.




# Hierarquia do Aprendizado



# Aprendizado Supervisionado

- ▶ Guiado por um “professor” externo
  - ▶ Professor possui conhecimento sobre o ambiente
    - ▶ Representado por conjunto de pares  $(x, y)$
    - ▶ **x: características** (atributos); **y: decisão** (classe)
  - ▶ Parâmetros do modelo indutivo são ajustados por apresentações sucessivas de pares  $(x, y)$ 
    - ▶ Modelo procura reproduzir comportamento do professor



# Aprendizado Supervisionado

---


- ▶ Após seu treinamento, desempenho do sistema deve ser testado com novos dados:
  - ▶ Dados de teste
  - ▶ Precisamos garantir a generalização das hipóteses aprendidas a outros dados
  - ▶ Logo:  $D_{teste} \cap D_{treinamento} = \emptyset$

# Aprendizado Supervisionado

- ▶ Após seu treinamento e teste, sistema pode ser aplicado a novos exemplos
  - ▶ Rotular os novos exemplos

| Variáveis Independentes (atributos) |      |     |       |     |      |    |
|-------------------------------------|------|-----|-------|-----|------|----|
| X1                                  | X2   | X3  | X4    | X5  | X6   | X7 |
| 53                                  | male | 140 | true  | 3.1 | down | 0  |
| 60                                  | male | 140 | false | 3   | flat | 0  |
| 40                                  | male | 140 | true  | 1.4 | up   | 0  |
| 57                                  | male | 165 | false | 1   | flat | 3  |
| 60                                  | male | 130 | true  | 1.4 | up   | 1  |
| 46                                  | fem  | 138 | true  | 0   | flat | 0  |
| 43                                  | male | 110 | false | 0   | up   | 0  |
| 58                                  | male | 120 | false | 1.8 | flat | 0  |
| 55                                  | male | 160 | true  | 0.8 | flat | 1  |
| 41                                  | male | 120 | false | 0   | up   | 0  |
| 52                                  | male | 172 | false | 0.5 | up   | 0  |
| 62                                  | fem  | 138 | false | 1.9 | flat | 3  |
| 43                                  | male | 120 | true  | 2.5 | flat | 0  |
| 47                                  | male | 110 | true  | 1   | flat | 1  |
| 56                                  | male | 130 | true  | 0.6 | flat | 1  |

**Não Rotulados  
(sem classe)**




| Variáveis Independentes (atributos) |      |     |       |     |      |    | Variável Dependente (classe) |
|-------------------------------------|------|-----|-------|-----|------|----|------------------------------|
| X1                                  | X2   | X3  | X4    | X5  | X6   | X7 | Y                            |
| 53                                  | male | 140 | true  | 3.1 | down | 0  | sick                         |
| 60                                  | male | 140 | false | 3   | flat | 0  | sick                         |
| 40                                  | male | 140 | true  | 1.4 | up   | 0  | buff                         |
| 57                                  | male | 165 | false | 1   | flat | 3  | sick                         |
| 60                                  | male | 130 | true  | 1.4 | up   | 1  | sick                         |
| 46                                  | fem  | 138 | true  | 0   | flat | 0  | buff                         |
| 43                                  | male | 110 | false | 0   | up   | 0  | buff                         |
| 58                                  | male | 120 | false | 1.8 | flat | 0  | sick                         |
| 55                                  | male | 160 | true  | 0.8 | flat | 1  | sick                         |
| 41                                  | male | 120 | false | 0   | up   | 0  | buff                         |
| 52                                  | male | 172 | false | 0.5 | up   | 0  | buff                         |
| 62                                  | fem  | 138 | false | 1.9 | flat | 3  | sick                         |
| 43                                  | male | 120 | true  | 2.5 | flat | 0  | sick                         |
| 47                                  | male | 110 | true  | 1   | flat | 1  | sick                         |
| 56                                  | male | 130 | true  | 0.6 | flat | 1  | sick                         |

**Exemplos Rotulados  
(com classe)**

# Aprendizado Não-Supervisionado

- ▶ Não possui informações externas
  - ▶ Extração de propriedades estatisticamente relevantes
  - ▶ Usa somente informações fornecidas pelos próprios dados
  - ▶ Exemplo: agrupamento de dados
    - ▶ Descobre categorias automaticamente



Keogh, E. A Gentle Introduction to Machine Learning and Data Mining for the Database Community, SBBD 2003, Manaus.

# Aprendizado Semissupervisionado

---

- ▶ Professor externo atua em somente uma parte dos exemplos usados para treinar o modelo
  - ▶ Exemplo: Web Mining
    - ▶ Usuários fornecem um conjunto de páginas similares, pertencentes a uma determinada categoria
    - ▶ Número de páginas com essa informação é extremamente pequeno quando comparado ao número total de páginas existentes

# Projetando um Sistema de Aprendizado

---

## ► Representatividade dos exemplos

- Aprendizado é mais confiável quando exemplos de treinamento seguem uma distribuição representativa(semelhante) à da população
- Ex.: Jogo de xadrez
  - Conjunto de treinamento formado apenas por exemplos de jogo contra o próprio programa
  - Experiência de treinamento pode não ser representativa

# Projetando um Sistema de Aprendizado

---

- ▶ Além do paradigma de treinamento e de dados representativos do problema, um sistema de AM deve ter:
  - ▶ **Função alvo**: tipo exato de conhecimento a ser aprendido
  - ▶ **Modelo**: uma representação para o conhecimento adquirido
  - ▶ **Técnica de aprendizado**: um mecanismo de aprendizado



# Função Alvo

---

- ▶ Estabelece o conhecimento que será aprendido e permite verificar o quão bem ele foi aprendido
  - ▶ Função discriminante entre classes, função de similaridade intra grupos, etc.
  - ▶ Exemplo: aprender a diagnosticar paciente de diabetes
    - ▶ Função?
      - Mapeamento entre características dos pacientes e os valores “diabético” e “não diabético”
    - ▶ Como aprender?
      - Ajustar a função aos dados disponíveis
    - ▶ Como determinar o desempenho da função aprendida?
      - Verificar quantos pacientes ela diagnostica corretamente

# Modelos de Representação

---

- ▶ Existem diversos paradigmas de AM
  - ▶ Simbólico
  - ▶ Conexionista
  - ▶ Estatístico
  - ▶ Baseado em Casos
  - ▶ Evolucionista
- ▶ Dentro dos paradigmas, diversos modelos podem ser encontrados

# Modelos de Representação

---

- ▶ **Modelos Matemáticos**

- ▶ Regressão Linear
- ▶ Redes Neurais
- ▶ Máquinas de vetores de suporte (SVM)

- ▶ **Modelos Simbólicos**

- ▶ Árvores de decisão
- ▶ Regras em lógica proposicional ou de 1ª ordem
- ▶ Redes semânticas

# Modelos de Representação

---

- ▶ Modelos “*Lazy*” (ou Baseados em Instâncias)
  - ▶ KNN
  - ▶ Raciocínio Baseado em Casos (CBR)
- ▶ Modelos Probabilísticos
  - ▶ Naive Bayes
  - ▶ Redes Bayesianas
  - ▶ Mistura de Gaussianas
  - ▶ Modelos de Markov Escondidos (HMMs)

# Técnicas de Aprendizado

---

- ▶ Dado um tipo de modelo, uma função alvo e um conjunto de objetos de treinamento, é preciso algum mecanismo para obter, a partir dos exemplos, um modelo específico daquele tipo que represente bem a função alvo
- ▶ Esse mecanismo, denominado mecanismo de aprendizado, consiste fundamentalmente de uma **técnica de busca**
  - ▶ Busca-se, no espaço de modelos, por aquele modelo específico que melhor represente a função alvo

# Avaliação em AM

---

- ▶ Uma vez obtido um modelo a partir de exemplos de treinamento e de uma técnica de aprendizado, é preciso **validar** o modelo
  - ▶ Avaliar a eficácia deste modelo para resolver a tarefa em questão
- ▶ **Avaliação Experimental**
  - ▶ Conduzir experimentos controlados e extrair medidas de desempenho
    - ▶ Acurácia de teste, tempos de treinamento e teste...
  - ▶ Analisar resultados e diferenças com rigor estatístico
- ▶ **Avaliação Teórica**
  - ▶ Analisar algoritmos matematicamente
  - ▶ Complexidade, habilidade para generalizar...


# Tarefas de AM

- ▶ A escolha do algoritmo de AM a ser utilizado depende da tarefa a ser realizada

| <b>Aprendiza-<br/>do</b><br><b>Tarefa</b> | <b>Aprendizado<br/>Supervisionado</b> | <b>Aprendizado<br/>Semissupervisionado</b> | <b>Aprendizado Não<br/>Supervisionado</b> |
|-------------------------------------------|---------------------------------------|--------------------------------------------|-------------------------------------------|
| Regressão<br>(classe contínua)            | ✓                                     | ✓                                          |                                           |
| Classificação<br>(classe discreta)        | ✓                                     | ✓                                          |                                           |
| Agrupamento<br>( <i>clustering</i> )      |                                       | ✓                                          | ✓                                         |
| Regras de<br>associação                   | ✓                                     |                                            | ✓                                         |

# O que usaremos no curso?

- ▶ As aulas terão as aplicações baseadas em Python
  - ▶ Linguagem interpretada de alto nível, de propósito geral
  - ▶ Ideal para desenvolvimento de scripts e aplicações rápidas em diversas áreas e várias plataformas
  - ▶ Interpretador gratuito e livremente distribuído
  - ▶ Top-1 Programming Languages em 2025



<https://spectrum.ieee.org/top-programming-languages-2025>



# Python

---

- ▶ Usaremos a versão  $\geq 3.10$ 
  - ▶ Mais estável
  - ▶ Vem na grande maioria das distribuições de Linux e MacOS. Usuários Windows podem baixar no site [www.python.org](http://www.python.org)
- ▶ Usaremos, também, bibliotecas gratuitas voltadas para análise de dados e aprendizado de máquina
  - ▶ Pandas (*Python Data Analysis Library*): <http://pandas.pydata.org/>
    - ▶ Manipulação de dados estacionários e séries de dados
  - ▶ Numpy e Scipy: <http://www.numpy.org/>
    - ▶ Bibliotecas de computação científica em Python
  - ▶ Matplotlib: <http://matplotlib.org/>
    - ▶ Plotagem de gráficos de diversos tipos
  - ▶ **Scikit-learn**: <http://scikit-learn.org/>
    - ▶ Algoritmos de aprendizado de máquina e manipulação de bases de dados

# Python

---

- ▶ Essas bibliotecas possuem dependências de outras bibliotecas
- ▶ Duas maneiras fáceis de lidar com isso:
  - ▶ Instalação manual por meio do pip
    - ▶ Funciona como um “apt-get” para bibliotecas do Python
    - ▶ <https://pypi.python.org/pypi/pip>
  - ▶ Instalação de uma versão do Python preparada para *data analysis*
    - ▶ Anaconda: <https://www.continuum.io/downloads>