




Introdução à Classificação e Regressão

Prof. Bruno Nogueira

Classificação

- ▶ É a tarefa de designar objetos a uma classe pertencente a um conjunto de classes predefinidas
- ▶ Formalmente: consiste no aprendizado de uma função objetivo **f** que mapeia um conjunto de atributos **x** a um dos rótulos de classes **y**



**Exemplos Não Rotulados
(sem classe)**

**Exemplos Rotulados
(com classe)**


Classificação vs. Regressão

- ▶ Classificação
 - ▶ Prediz rótulos de classes **categóricos**
 - ▶ Classifica os dados baseado em um conjunto de treinamento e os valores (rótulos de classe) em um atributo classificador
- ▶ Regressão
 - ▶ Modela funções de valores contínuos
- ▶ Para entendermos alguns conceitos, vamos focar em classificação, inicialmente...


Processo de Classificação

- ▶ Constituído de dois passos
 - ▶ **Aprendizado (ou treinamento)**: constrói o modelo de classificação
 - ▶ Utiliza um conjunto de dados para os quais é sabido o valor da classe
 - ▶ **Classificação**: modelo é utilizado para prever a classe de um objeto
 - ▶ Aplicado sobre objetos para os quais não se sabe o valor da classe
- ▶ Fase de aprendizado resulta na função $y=f(x)$
 - ▶ Este mapeamento é apresentado na forma de regras de classificação, árvores de decisão ou fórmulas matemáticas

Aprendizado e Classificação



Aprendizado e Classificação




Aprendizado e Classificação

- ▶ Em quase todos os problemas de classificação, há uma interpretação geométrica
- ▶ O problema anterior era extremamente simples
 - ▶ Era possível aprender um modelo perfeito utilizando apenas uma linha
 - ▶ Chamamos de problema **Linearmente Separável**
 - ▶ Para classificarmos uma nova instância ainda não vista, basta usar um **Classificador Linear Simples**




Se instância ainda não vista está acima da linha
 Classe Feliz

Senão
 Classe Triste



Aprendizado e Classificação


- ▶ Mas nem todos os problemas são linearmente separáveis...
- ▶ Na verdade, quase nenhum problema real é linearmente separável!




Exemplo: Dados sobre Crédito Bancário

Idade	Renda	Classe
20	2000	Ruim
30	5100	Bom
60	5000	Ruim
40	6000	Bom
...	...	...


Árvore de Decisão




Árvore de Decisão





Árvore de Decisão



Árvore de Decisão



Árvore de Decisão





Idade

● Ruim

● Bom



Árvore de Decisão



Idade

● Ruim
● Bom



Árvore de Decisão



● **Ruim**

● **Bom**



Árvore de Decisão



● Ruim



● Bom

Árvore de Decisão



● Ruim
● Bom



Árvore de Decisão



● Ruim

● Bom



Árvore de Decisão



● Ruim

● Bom

Árvore de Decisão





● Ruim
● Bom

Idade



5 - Ruim
0 - Bom

Árvore de Decisão




● Ruim
● Bom

Árvore de Decisão




● Ruim
● Bom



Árvore de Decisão (H1)


Renda



Idade

...Outra Possível H2


Renda



Idade

...Outra Possível H3


Renda



Idade


...Outra Possível H4

Renda



Idade

Qual a melhor Hipótese?




- ▶ Avaliação em conjunto de teste
 - ▶ Dados não vistos durante o processo de treinamento (indução da hipótese)

$$D_{teste} \cap D_{treinamento} = \emptyset$$

Erro de H4

Conjunto de Teste


Renda



Idade

Conjunto de Teste


Renda




Idade

Avaliação de classificadores

- ▶ Nem sempre, a melhor hipótese para o conjunto de treinamento é a melhor para os demais casos
 - ▶ **Overfitting**: sobreajuste ao conjunto de treinamento
 - ▶ Modelo “aprende demais” o conjunto de treinamento e não consegue ser generalizado para exemplos não vistos




Conjunto de
Treinamento



Conjunto de
Teste

Avaliação de regressores

- ▶ Já havíamos visto antes que o problema de *overfitting* por, também, ocorrer em algoritmos de regressão



Como avaliar um classificador

- ▶ **Métricas para avaliar a performance de um classificador**
 - ▶ Aplicadas sobre o desempenho do classificador quando vendo os exemplos do conjunto de teste
- ▶ **Essas métricas são baseadas em uma matriz de confusão**
 - ▶ Dadas m classes ($m \geq 2$), uma matriz de confusão é uma tabela de tamanho $m \times m$
 - ▶ Uma entrada MC_{ij} indica o número de exemplos da classe i que foram rotulados pelo classificador como sendo da classe j
 - ▶ Idealmente, a maioria dos exemplos deve pertencer a uma diagonal da matriz de confusão

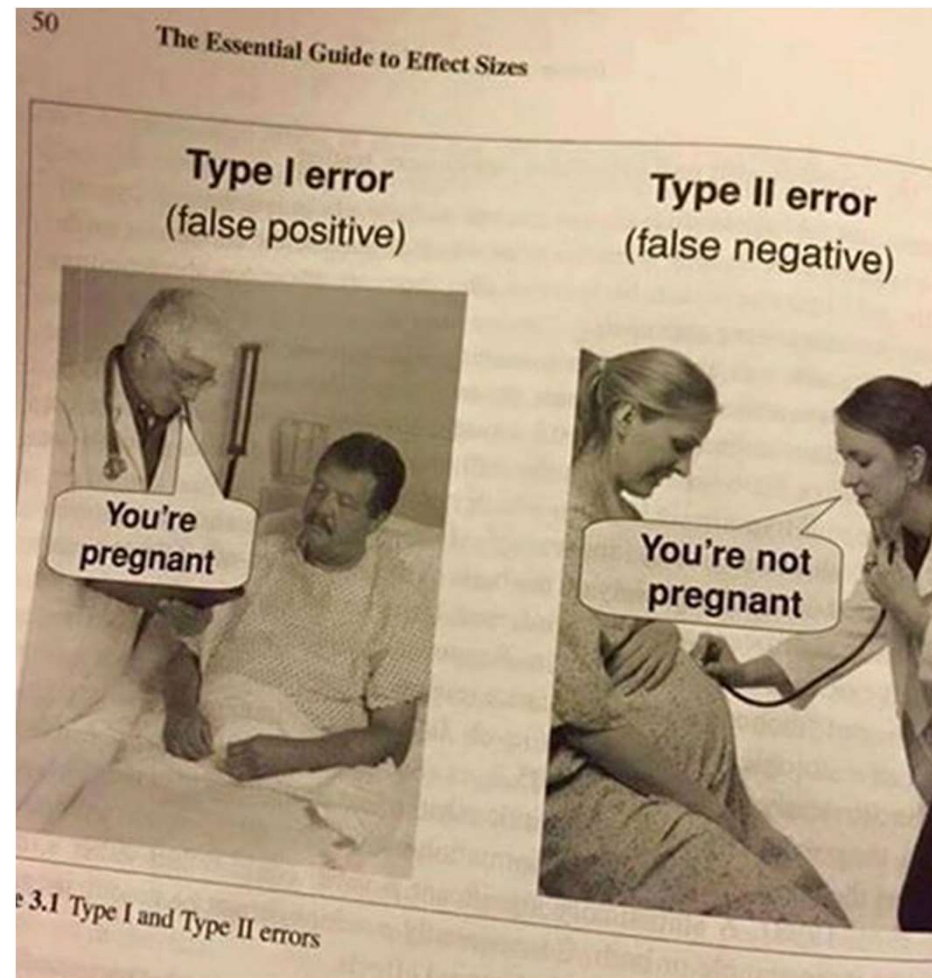
Como avaliar um classificador

▶ Exemplo: Classificação com duas classes (+ e -)

		Classe Preditada	
		+	-
Classe Real	+	TP	FN
	-	FP	TN

- ▶ TP (*True Positives*): número de exemplos positivos que foram corretamente rotulados pelo classificador
- ▶ TN (*True Negatives*): número de exemplos negativos que foram corretamente rotulados pelo classificador
- ▶ FP (*False Positives*): número de exemplos negativos que foram incorretamente rotulados pelo classificador como positivos
- ▶ FN (*False Negatives*): número de exemplos positivos que foram incorretamente rotulados pelo classificador como sendo negativos

Falso positivo x Falso negativo



Como avaliar um classificador

- ▶ Normalmente, utiliza-se a **taxa de acerto (acurácia)** ou a **taxa de erro** para avaliar e comparar classificadores
- ▶ **Erro majoritário**
 - ▶ Supondo que, no conjunto de teste, temos 70% de elementos pertencendo à classe positiva e 30% à classe negativa
 - ▶ Dizemos que a classe majoritária tem 70%
 - ▶ Um classificador que rotula todos os exemplos como sendo da classe majoritária terá uma taxa de erro de 30%
 - ▶ Logo, o erro majoritário desta base será de 30%.
 - ▶ Um classificador mostra que aprendeu quando o erro apresentado é **menor** que o erro majoritário

Medidas de avaliação de classificadores

2 Classes



Medida	Fórmula
Acurácia / Taxa de acerto	$\frac{TP + TN}{P + N}$
Taxa de erro	$\frac{FP + FN}{P + N}$
Revocação / Taxa de verdadeiros positivos / Sensitividade	$\frac{TP}{P}$
Taxa de verdadeiros negativos / Especificidade	$\frac{TN}{N}$
Precisão	$\frac{TP}{TP + FP}$
F1 Measure / Média harmônica entre precisão e revocação	$\frac{2 * \textit{precisão} * \textit{revocação}}{\textit{precisão} + \textit{revocação}}$

Medidas de avaliação de classificadores

2 Classes



► Revocação: medida de **completude**

- Porcentagem de exemplos rotulados corretamente como positivos considerando os exemplos que realmente são positivos
- Revocação = $\frac{TP}{P}$
 - Significa que o classificador conseguiu associar corretamente todos os elementos da classe positiva
 - Não diz o número de exemplos de outras classe que foram classificados como sendo da classe positiva

		Classe Predita	
		+	-
Classe Real	+	TP	FN
	-	FP	TN

$$revocação = \frac{TP}{P}$$

Medidas de avaliação de classificadores

2 Classes



► Precisão: medida de **exatidão**

- Porcentagem de exemplos rotulados corretamente como positivos considerando os exemplos que o classificador rotulou como positivos
- Precisão = I
 - Significa que cada exemplo que o classificador rotulou como sendo da classe C realmente pertence a classe positiva
 - Não diz o numero de exemplos da classe positiva que foram classificados erroneamente

		Classe Predita	
		+	-
Classe Real	+	TP	FN
	-	FP	TN

$$precisão = \frac{TP}{TP + FP}$$

Medidas de avaliação de classificadores

2 Classes



► Exemplo de avaliação de classificadores

Classificador 1		Classe Predita	
		+	-
Classe Real	+	5	5
	-	0	10

$$\text{Acurácia} = \frac{5+10}{5+5+10} = 75\%$$

$$\text{Precisão} = \frac{5}{5} = 100\%$$

$$\text{Revocação} = \frac{5}{5+5} = 50\%$$

$$F1 = \frac{2 * 1 * 0,5}{1 + 0,5} = 67\%$$

Classificador 2		Classe Predita	
		+	-
Classe Real	+	5	0
	-	10	5

$$\text{Acurácia} = \frac{5+5}{5+5+10} = 50\%$$

$$\text{Precisão} = \frac{5}{5+10} = 33\%$$

$$\text{Revocação} = \frac{5}{5} = 100\%$$

$$F1 = \frac{2 * 0,33 * 1}{0,33 + 1} = 49\%$$

Medidas de avaliação de classificadores

Mais de duas classes



- ▶ Para problemas envolvendo mais de 2 classes, faz-se uma matriz de confusão para todas as classes

		Classe Predita		
		A	B	C
Classe Real	A	TP_A	E_{AB}	E_{AC}
	B	E_{BA}	TP_B	E_{BC}
	C	E_{CA}	E_{CB}	TP_C

Medidas de avaliação de classificadores

Mais de duas classes



- ▶ Para estimar medidas como precisão e revocação, dois métodos podem ser adotados: **microaveraging** e **macroaveraging**
- ▶ Microaveraging: soma dos componentes das medidas individualmente

$$Precisão = \frac{\sum_{i=1}^{|C|} TP_i}{\sum_{i=1}^{|C|} (TP_i + FP_i)}$$

$$Revocação = \frac{\sum_{i=1}^{|C|} TP_i}{\sum_{i=1}^{|C|} (TP_i + FN_i)}$$

Medidas de avaliação de classificadores

Mais de duas classes



- Macroaveraging: as medidas são avaliadas localmente e depois faz a média global

$$Precisão = \frac{\sum_{i=1}^{|C|} Precisão_i}{|C|}$$

$$Revocação = \frac{\sum_{i=1}^{|C|} Revocação_i}{|C|}$$


Estimando a performance de classificadores



- ▶ Como podemos estimar o desempenho de um classificador quando enfrentar dados novos?
 - ▶ Se utilizarmos os mesmos dados que utilizamos no treinamento do classificador, a avaliação pode ser tendenciosa!
 - ▶ Problema de sobreajuste aos dados de treinamento
- ▶ Solução: utilizar um **conjunto de teste**
 - ▶ Conjunto de dados para os quais se sabe o valor de classe, mas não estão no conjunto de treinamento
- ▶ Duas maneiras básicas de selecionar conjuntos de teste
 - ▶ Holdout
 - ▶ K-Fold Cross Validation

Holdout


- ▶ O conjunto de dados é particionado aleatoriamente em dois conjuntos: treino e teste
- ▶ Tipicamente, $\frac{2}{3}$ dos dados são separados para treinamento e o restante para teste



K-Fold Cross Validation

- ▶ Os dados são separados em k subconjuntos independentes e de tamanhos iguais, denominados **folds** ($D_1, D_2, \dots, D_k$)
- ▶ Procedimento de treino e teste é realizado k vezes
 - ▶ A cada iteração i , D_i é utilizado para teste, enquanto todos os outros $k-1$ folds são usados para treinamento
 - ▶ O resultado da classificação é a média dos resultados das classificações
 - ▶ Normalmente, é utilizado um $k = 10$ (**10-Fold Cross Validation**)
- ▶ Cross-validation estratificado: folds são gerados de maneira que a distribuição das classes dos elementos dentro dos folds sejam aproximadamente as mesmas

K-Fold Cross Validation



Exemplo

- Considere a seguinte base de dados:

Paciente	Tosse	Febre	Dor de Cabeça	Doente
P1	SIM	NÃO	SIM	SIM
P2	NÃO	NÃO	SIM	NÃO
P3	SIM	NÃO	NÃO	NÃO
P4	SIM	SIM	SIM	SIM
P5	NÃO	SIM	SIM	SIM
P6	SIM	NÃO	NÃO	SIM
P7	NÃO	NÃO	NÃO	NÃO
P8	NÃO	SIM	NÃO	SIM
P9	NÃO	NÃO	NÃO	NÃO
P10	SIM	SIM	SIM	SIM

Exemplo

- Considere a seguinte base de dados:

ATRIBUTOS	Paciente	Tosse	Febre	Dor de Cabeça	Doente	CLASSE
	P1	SIM	NÃO	SIM	SIM	
	P2	NÃO	NÃO	SIM	NÃO	
	P3	SIM	NÃO	NÃO	NÃO	
	P4	SIM	SIM	SIM	SIM	
	P5	NÃO	SIM	SIM	SIM	
	P6	SIM	NÃO	NÃO	SIM	
	P7	NÃO	NÃO	NÃO	NÃO	
	P8	NÃO	SIM	NÃO	SIM	
	P9	NÃO	NÃO	NÃO	NÃO	
	P10	SIM	SIM	SIM	SIM	

Exemplo

- ▶ Esse conjunto já rotulado será usado para **treinar** o classificador (induzir a função / hipótese de classificação)
- ▶ Também será utilizado para **testar** o desempenho dessa função
- ▶ Precisamos separar
 - ▶ Conjunto de treinamento
 - ▶ Conjunto de teste
 - ▶ São **DISJUNTOS**

Paciente	Tosse	Febre	Dor de Cabeça	Doente
P1	SIM	NÃO	SIM	SIM
P2	NÃO	NÃO	SIM	NÃO
P3	SIM	NÃO	NÃO	NÃO
P4	SIM	SIM	SIM	SIM
P5	NÃO	SIM	SIM	SIM
P6	SIM	NÃO	NÃO	SIM
P7	NÃO	NÃO	NÃO	NÃO
P8	NÃO	SIM	NÃO	SIM
P9	NÃO	NÃO	NÃO	NÃO
P10	SIM	SIM	SIM	SIM

Exemplo

► Holdout

- Separamos aleatoriamente 2/3 para treino e 1/3 para teste

Paciente	Tosse	Febre	Dor de Cabeça	Doente	
P1	SIM	NÃO	SIM	SIM	TREINO
P2	NÃO	NÃO	SIM	NÃO	TESTE
P3	SIM	NÃO	NÃO	NÃO	TREINO
P4	SIM	SIM	SIM	SIM	TREINO
P5	NÃO	SIM	SIM	SIM	TREINO
P6	SIM	NÃO	NÃO	SIM	TESTE
P7	NÃO	NÃO	NÃO	NÃO	TREINO
P8	NÃO	SIM	NÃO	SIM	TESTE
P9	NÃO	NÃO	NÃO	NÃO	TESTE
P10	SIM	SIM	SIM	SIM	TREINO

Exemplo

► Holdout

- Conjunto formado por P1, P3, P4, P5, P7 e P10 é apresentado ao classificador para o processo de **treinamento**
- Conjunto formado por P2, P6, P8 e P9 é utilizado para o processo de teste (comparação da saída gerada pelo classificador – classe predita - com a classe real)

Paciente	Tosse	Febre	Dor de Cabeça	Doente
P1	SIM	NÃO	SIM	SIM
P2	NÃO	NÃO	SIM	NÃO
P3	SIM	NÃO	NÃO	NÃO
P4	SIM	SIM	SIM	SIM
P5	NÃO	SIM	SIM	SIM
P6	SIM	NÃO	NÃO	SIM
P7	NÃO	NÃO	NÃO	NÃO
P8	NÃO	SIM	NÃO	SIM
P9	NÃO	NÃO	NÃO	NÃO
P10	SIM	SIM	SIM	SIM

Exemplo

► Holdout

Vamos assumir que estas sejam as saídas geradas pelo classificador para exemplos de teste

Paciente	Tosse	Febre	Dor de Cabeça	Doente	
P1	SIM	NÃO	SIM	SIM	NÃO
P2	NÃO	NÃO	SIM	NÃO	
P3	SIM	NÃO	NÃO	NÃO	
P4	SIM	SIM	SIM	SIM	NÃO
P5	NÃO	SIM	SIM	SIM	
P6	SIM	NÃO	NÃO	SIM	
P7	NÃO	NÃO	NÃO	NÃO	SIM
P8	NÃO	SIM	NÃO	SIM	
P9	NÃO	NÃO	NÃO	NÃO	SIM
P10	SIM	SIM	SIM	SIM	

Exemplo

► Holdout

Paciente	Tosse	Febre	Dor de Cabeça	Doente	
P1	SIM	NÃO	SIM	SIM	
P2	NÃO	NÃO	SIM	NÃO	NÃO
P3	SIM	NÃO	NÃO	NÃO	
P4	SIM	SIM	SIM	SIM	
P5	NÃO	SIM	SIM	SIM	
P6	SIM	NÃO	NÃO	SIM	NÃO
P7	NÃO	NÃO	NÃO	NÃO	
P8	NÃO	SIM	NÃO	SIM	SIM
P9	NÃO	NÃO	NÃO	NÃO	SIM
P10	SIM	SIM	SIM	SIM	

		Classe Predita	
		+	-
Classe Real	+	?	?
	-	?	?

Exemplo

► Holdout

Paciente	Tosse	Febre	Dor de Cabeça	Doente	
P1	SIM	NÃO	SIM	SIM	
P2	NÃO	NÃO	SIM	NÃO	NÃO
P3	SIM	NÃO	NÃO	NÃO	
P4	SIM	SIM	SIM	SIM	
P5	NÃO	SIM	SIM	SIM	
P6	SIM	NÃO	NÃO	SIM	NÃO
P7	NÃO	NÃO	NÃO	NÃO	
P8	NÃO	SIM	NÃO	SIM	SIM
P9	NÃO	NÃO	NÃO	NÃO	SIM
P10	SIM	SIM	SIM	SIM	

		Classe Predita	
		+	-
Classe Real	+		
	-		

Exemplo

► Holdout

		Classe Preditada	
		+	-
Classe Real	+	1	1
	-	1	1

$$Acuracia = \frac{TP + TN}{P + N} = ?$$

$$Revocação = \frac{TP}{P} = ?$$

$$Precisão = \frac{TP}{TP + FP} = ?$$

Exemplo

► Holdout

		Classe Predit	
		+	-
Classe Real	+	1	1
	-	1	1

$$Acuracia = \frac{TP + TN}{P + N} = \frac{1 + 1}{4} = 50\%$$

$$Re\ voca\c{c}\tilde{a}o = \frac{TP}{P} = \frac{1}{2} = 50\%$$

$$Pr\ ecis\tilde{a}o = \frac{TP}{TP + FP} = \frac{1}{1 + 1} = 50\%$$

Exemplo

► K-fold Cross Validation

- Separamos nosso conjunto em K subconjuntos
- Quando estratificado, proporção de classes é mantida (ou aproximadamente mantida) nos folds

Paciente	Tosse	Febre	Dor de Cabeça	Doente
P1	SIM	NÃO	SIM	SIM
P2	NÃO	NÃO	SIM	NÃO
P3	SIM	NÃO	NÃO	NÃO
P4	SIM	SIM	SIM	SIM
P5	NÃO	SIM	SIM	SIM
P6	SIM	NÃO	NÃO	SIM
P7	NÃO	NÃO	NÃO	NÃO
P8	NÃO	SIM	NÃO	SIM
P9	NÃO	NÃO	NÃO	NÃO
P10	SIM	SIM	SIM	SIM

60% SIM
40% NÃO

Exemplo

► K-fold Cross Validation

- Vamos usar $k = 3$ e estratificado
- Sorteie-se aleatoriamente, mantendo as proporções de classes

Paciente	Tosse	Febre	Dor de Cabeça	Doente	
P1	SIM	NÃO	SIM	SIM	Fold 1
P2	NÃO	NÃO	SIM	NÃO	Fold 2
P3	SIM	NÃO	NÃO	NÃO	Fold 1
P4	SIM	SIM	SIM	SIM	Fold 2
P5	NÃO	SIM	SIM	SIM	Fold 1
P6	SIM	NÃO	NÃO	SIM	Fold 3
P7	NÃO	NÃO	NÃO	NÃO	Fold 3
P8	NÃO	SIM	NÃO	SIM	Fold 2
P9	NÃO	NÃO	NÃO	NÃO	Fold 3
P10	SIM	SIM	SIM	SIM	Fold 3

Exemplo

► K-fold Cross Validation

- Processo é repetido k vezes, gerando k matrizes de confusão

Fold 1		Classe Preditá	
		+	-
Classe Real	+	2	0
	-	1	0

Fold 3		Classe Preditá	
		+	-
Classe Real	+	1	1
	-	0	2

Fold 2		Classe Preditá	
		+	-
Classe Real	+	1	1
	-	0	1

Exemplo

► K-fold Cross Validation

► Matriz final é feita pela SOMA das demais

Fold 1		Classe Predita	
		+	-
Classe Real	+	2	0
	-	1	0

Fold 3		Classe Predita	
		+	-
Classe Real	+	1	1
	-	0	2

Fold 2		Classe Predita	
		+	-
Classe Real	+	1	1
	-	0	1

Final		Classe Predita	
		+	-
Classe Real	+	4	2
	-	1	3

Exemplo

► K-Fold Cross Validation

Final		Classe Predita	
		+	-
Classe Real	+	4	2
	-	1	3

$$Acuracia = \frac{TP + TN}{P + N} = ?$$

$$Re\ vocação = \frac{TP}{P} = ?$$

$$Pr\ ecisão = \frac{TP}{TP + FP} = ?$$

Exemplo

► K-Fold Cross Validation

Final		Classe Predita	
		+	-
Classe Real	+	4	2
	-	1	3

$$Acuracia = \frac{TP + TN}{P + N} = \frac{4 + 3}{6 + 4} = 70\%$$

$$Revocação = \frac{TP}{P} = \frac{4}{6} = 67\%$$

$$Precisão = \frac{TP}{TP + FP} = \frac{4}{4 + 1} = 80\%$$

Holdout x Cross Validation

- ▶ Geralmente, a validação cruzada é preferível
 - ▶ Estatisticamente, a avaliação da validação cruzada é menos enviesada (*biased*) do que a holdout
 - ▶ Variância dos resultados pode ser alta, mas o problema é amenizado com as k repetições
- ▶ Holdout é mais indicado em casos em que se tem poucos dados
 - ▶ A separação de um dataset pequeno em k subconjuntos pode tornar a análise muito enviesada, inviabilizando a validação cruzada

Exercício

- Mostre as matrizes de confusão para cada fold, a matriz de confusão resultante do processo de teste e os valores de acurácia, revocação e precisão

Paciente	Tosse	Febre	Dor de Cabeça	Doente	Saída
P1	SIM	NÃO	SIM	SIM	NÃO
P2	NÃO	NÃO	SIM	NÃO	SIM
P3	SIM	NÃO	NÃO	NÃO	SIM
P4	SIM	SIM	SIM	SIM	NÃO
P5	NÃO	SIM	SIM	SIM	SIM
P6	SIM	NÃO	NÃO	SIM	SIM
P7	NÃO	NÃO	NÃO	NÃO	SIM
P8	NÃO	SIM	NÃO	SIM	NÃO
P9	NÃO	NÃO	NÃO	NÃO	NÃO
P10	SIM	SIM	SIM	SIM	NÃO